



UNIVERSIDAD
DE BURGOS



Trabajo Fin de Máster — Anexos
Máster Universitario en Ingeniería Biomédica

Evaluación computacional de
nanopartículas poliméricas y
dendrimeros como sistemas de liberación
de fármacos: acoplamiento molecular con
proteínas de barrera biológica y modelos
predictivos de eficiencia de transporte

Presentado por **Diego Vallina Álvarez**

Universidad de Burgos · Curso académico 2025–2026

Directores:

Santiago Aparicio Martínez

Pedro Ángel Marcos Villa

Índice general

Índice general	1
Índice de figuras	3
Índice de tablas	4
Apéndice A Planificación del proyecto	5
A.1. Fases de desarrollo	5
A.2. Infraestructura computacional	5
A.3. Software utilizado	5
Apéndice B Base de datos molecular	8
Apéndice C Detalles de los cálculos cuánticos	11
C.1. Parámetros generales	11
C.2. Casos especiales	11
C.3. Archivos generados por molécula	12
C.4. Estadísticas de convergencia	12
Apéndice D Resultados completos de docking	13
D.1. Protocolo de preparación	13
D.2. Energías de unión	13
Apéndice E Descriptores moleculares y modelos ML	15
E.1. Espacio de descriptores	15
E.2. Pipeline de preprocesado	16
E.3. Resultados del Modelo 1: regresión de afinidad	16
E.4. Resultados del Modelo 3: clasificador	16

E.5. Variables más importantes según SHAP	17
Apéndice F Código fuente	19
F.1. Scripts del clúster HPC	19
F.2. Scripts locales	20
F.3. Dependencias	20
Apéndice G Herramienta web Streamlit	21
Apéndice H Objetivos de Desarrollo Sostenible	30
Bibliografía	31

Índice de figuras

G.1. Pantalla de inicio. El usuario puede introducir el SMILES directamente o seleccionar una molécula del dataset del TFM filtrando por grupo molecular.	22
G.2. Visualización 3D interactiva con py3Dmol y propiedades moleculares calculadas automáticamente.	23
G.3. Resultados del análisis: métricas ITI, radar chart del perfil de afinidad, tabla de ΔG predichos y recomendación de carrier. . .	24
G.4. Pestaña de ranking ITI. Las líneas discontinuas marcan los umbrales favorable (>66) y moderado (>33).	25
G.5. Comparador: gráfico de barras agrupadas con los ΔG predichos para las moléculas seleccionadas.	26
G.6. Comparador: radar charts individuales de cada molécula.	27
G.7. Pestaña de historial: mapa de calor de ΔG para todas las moléculas analizadas en la sesión actual.	28

Índice de tablas

A.1. Plan de trabajo por fases.	6
A.2. Recursos computacionales empleados.	7
A.3. Software empleado en el proyecto.	7
B.1. Base de datos molecular completa (60 moléculas).	8
D.1. Estadísticas de energía de unión por proteína (kcal/mol).	14
D.2. Energía de unión media por grupo molecular (kcal/mol, media sobre las 6 proteínas).	14
E.1. Familias de descriptores moleculares calculados y retenidos tras la limpieza.	15
E.2. R^2 y MAE (kcal/mol) en validación cruzada de 5 particiones. . .	16
E.3. Métricas del clasificador favorable/desfavorable (5-fold CV estratificado). AUC-ROC mide la capacidad de separar las dos clases; un valor de 1 es perfecto.	17
E.4. Top 10 variables por importancia SHAP (modelo RF, P-gp MDR1). .	17

Apéndice A

Planificación del proyecto

A.1. Fases de desarrollo

El proyecto se dividió en siete fases. No siguieron un orden estrictamente secuencial: las fases 3 y 4 se solaparon porque los cálculos cuánticos tardaban semanas y era posible preparar el docking en paralelo.

A.2. Infraestructura computacional

Los cálculos cuánticos y de docking se ejecutaron en el clúster HPC del Centro Extremeño de Investigación, Innovación Tecnológica y Supercomputación (CENITS), con acceso por SSH y gestión de colas con SLURM. El equipo local fue un MacBook Air M1 con 16,GB de RAM, usado para el análisis de datos, las figuras y la redacción.

A.3. Software utilizado

Tabla A.1: Plan de trabajo por fases.

Fase	Periodo	Descripción
Fase 1	Semanas 1–2	Revisión bibliográfica sobre nanopartículas poliméricas, dendrímeros y proteínas de barrera. Formación en TURBOMOLE TURBOMOLE GmbH (2023) , AutoDock Vina Eberhardt et al. (2021) y RDKit RDKit (2023) .
Fase 2	Semanas 3–4	Construcción de la base de datos molecular (58 moléculas). Obtención de estructuras desde PubChem. Generación de coordenadas 3D iniciales con RDKit.
Fase 3	Semanas 4–8	Cálculos cuánticos (B3LYP-D4/def2-TZVP) en clúster HPC CENITS: optimización de estructuras, distribución de carga superficial (COSMO-RS) y frecuencias de vibración IR. Resolución de casos especiales: Cisplatino, Condroitín sulfato, Paclitaxel y Sirolimus.
Fase 4	Semanas 7–9	Docking con AutoDock Vina 1.2.5: 342 cálculos automatizados con Python.
Fase 5	Semanas 9–11	Cálculo de descriptores moleculares con RDKit RDKit (2023) y Mordred Moriwaki et al. (2018) . Construcción del dataset para los modelos ML.
Fase 6	Semanas 11–13	Modelos ML, análisis SHAP Lundberg and Lee (2017) , análisis de interacciones con PLIP Schake et al. (2025) y propiedades farmacológicas con SwissADME Daina et al. (2017) .
Fase 7	Semanas 13–16	Implementación de la herramienta Streamlit. Redacción de memoria y anexos.

Tabla A.2: Recursos computacionales empleados.

Recurso	Especificación
Clúster	HPC CENITS, partición lusi2
CPUs por nodo	16 núcleos
RAM por nodo	31 GB
Gestor de colas	SLURM
Tiempo de cómputo DFT	~3 semanas acumuladas
Tiempo de cómputo docking	~4 días acumulados
Equipo local	MacBook Air M1, 16 GB RAM

Tabla A.3: Software empleado en el proyecto.

Software	Versión	Uso
TURBOMOLE	7.8.1	Cálculos cuánticos TURBOMOLE GmbH (2023)
AutoDock Vina	1.2.5	Docking molecular Eberhardt et al. (2021)
MGLTools	1.5.7	Preparación de proteínas
OpenBabel	3.1.0	Conversión de formatos
RDKit	2023.09	Descriptores y fingerprints RDKit (2023)
Mordred	1.2.0	Descriptores 3D Moriwaki et al. (2018)
scikit-learn	1.3.0	Modelos ML
SHAP	0.44.0	Interpretabilidad Lundberg and Lee (2017)
PLIP	2025	Análisis de interacciones Schake et al. (2025)
SwissADME	web	Propiedades ADMET Daina et al. (2017)
Streamlit	1.32.0	Herramienta web
Python	3.12	Scripts de automatización
Quarto	1.5	Redacción de la memoria

Apéndice B

Base de datos molecular

La biblioteca molecular se construyó a partir de SMILES obtenidos de PubChem [RDKit](#) (2023). Para cada molécula se verificó la estructura manualmente y se descartaron las que daban error de parseo en RDKit. El dataset final tiene 60 entradas, de las que 58 generaron geometrías DFT convergidas y 56 se usaron para el entrenamiento ML.

Las columnas MW y LogP se calcularon con RDKit sobre los SMILES canónicos. El CID es el identificador de PubChem.

Tabla B.1: Base de datos molecular completa (60 moléculas).

Grupo	Nombre	MW (Da)	LogP
<i>Monómeros y productos de degradación (15)</i>			
Monómeros	L-Lactic acid	90.1	−0.55
Monómeros	D-Lactic acid	90.1	−0.55
Monómeros	Glycolic acid	76.1	−0.94
Monómeros	Succinic acid	118.1	−0.06
Monómeros	Glutaric acid	132.1	0.33
Monómeros	Adipic acid	146.1	0.72
Monómeros	6-Hydroxyhexanoic acid	132.2	0.62
Monómeros	epsilon-Caprolactone	114.1	1.10
Monómeros	Glucosamine	179.2	−3.25
Monómeros	N-Acetylglucosamine	221.2	−3.23
Monómeros	Ethylenediamine	60.1	−1.10
Monómeros	Methyl acrylate	86.1	0.35
Monómeros	L-Lactide	144.1	−0.14

Monómeros	Glycolide	116.1	-0.91
<i>Oligómeros y unidades de dendrímero (20)</i>			
Oligómeros	Diethylenetriamine	103.2	-1.51
Oligómeros	Triethylenetetramine	146.2	-1.92
Oligómeros	Tetraethylenepentamine	189.3	-2.33
Oligómeros	Pentaethylenehexamine	232.4	-2.74
Oligómeros	Tris(2-aminoethyl)amine	146.2	-1.84
Oligómeros	Methylamine	31.1	-0.43
Oligómeros	Ammonia	17.0	0.16
Oligómeros	2-Aminoethanol	61.1	-1.06
Oligómeros	2-(2-Aminoethoxy)ethanol	105.1	-1.05
Oligómeros	Bis(2-aminoethyl) ether	104.2	-1.08
Oligómeros	Methyl 3-aminopropionate	103.1	-0.49
Oligómeros	Ethyl acrylate	100.1	0.74
Oligómeros	Methyl methacrylate	100.1	0.74
Oligómeros	Acrylic acid	72.1	0.26
Oligómeros	Lactic acid dimer	162.1	-0.62
Oligómeros	Lactic acid trimer	234.2	-0.68
Oligómeros	Diglycolic acid	134.1	-0.83
Oligómeros	Chitobiose	340.3	-5.62
Oligómeros	Chitotriose	501.5	-7.83
<i>Fármacos modelo (10)</i>			
Fármacos	Doxorubicin	543.5	0.00
Fármacos	Paclitaxel	853.9	3.74
Fármacos	5-Fluorouracil	130.1	-0.80
Fármacos	Methotrexate	454.4	0.27
Fármacos	Curcumin	368.4	3.37
Fármacos	Cisplatin	300.0	1.70
Fármacos	Gemcitabine	263.2	-1.29
Fármacos	Sirolimus	914.2	6.18
Fármacos	Dexamethasone	392.5	1.90
Fármacos	Ibuprofen	206.3	3.07
<i>Ligandos de targeting activo (15)</i>			
Ligandos	Folic acid	441.4	-0.04
Ligandos	Biotin	244.3	0.80
Ligandos	D-Mannose	180.2	-3.22
Ligandos	D-Galactose	180.2	-3.22
Ligandos	N-Acetylneuraminic acid	309.3	-3.87
Ligandos	Glucuronic acid	194.1	-3.13
Ligandos	Glucosamine-6-sulfate	259.2	-3.43

Base de datos molecular

Ligandos	Chondroitin sulfate disaccharide	555.4	−6.19
Ligandos	Arginylglycylaspartic acid	346.3	−3.47
Ligandos	Asparagine	132.1	−1.73
Ligandos	Arginine	174.2	−1.55
Ligandos	Aspartic acid	133.1	−1.13
Ligandos	4-Aminobenzoic acid	137.1	0.97
Ligandos	2,2'-Iminodiethanol	105.1	−1.44
Ligandos	Triethylene glycol	150.2	−1.00

Los SMILES completos están en el archivo `base_molecular_pubchem.csv` del repositorio. Los fármacos modelo tienen los pesos moleculares más altos, con Sirolimus (914.2 Da) y Paclitaxel (853.9 Da) en los extremos. Los oligómeros de quitosano son los más hidrofílicos, con LogP de −5.62 (Chitobiose) y −7.83 (Chitotriose).

Apéndice C

Detalles de los cálculos cuánticos

C.1. Parámetros generales

Todos los cálculos se hicieron con TURBOMOLE 7.8.1 [TURBOMOLE GmbH \(2023\)](#) en el clúster HPC CENITS. El nivel de cálculo fue B3LYP con corrección de dispersión D4 [Grimme et al. \(2010\)](#) y base de funciones def2-TZVP [Weigend and Ahlrichs \(2005\)](#), con aproximación RI-J para reducir el coste computacional. Para cada molécula se hicieron tres cálculos en secuencia: optimización de la estructura hasta el mínimo de energía, cálculo de la distribución de carga superficial (COSMO-RS) y cálculo de frecuencias de vibración IR. Estas frecuencias sirven para confirmar que la estructura encontrada es un mínimo real y no un punto de silla en la superficie de energía.

El criterio de parada para la optimización fue un gradiente de energía menor de 10^{-4} Hartree/Bohr.

C.2. Casos especiales

Cuatro moléculas necesitaron un tratamiento distinto al estándar.

Cisplatino. El platino no tiene parámetros en la base def2-TZVP. Se usó el pseudopotencial de Stuttgart ECP-60-mwb con base def2-SVP para el platino y def2-TZVP para el resto de átomos. Las frecuencias confirmaron una geometría cuadrado-planar, que es la esperada para complejos de platino(II).

Condroitín sulfato disacárido. Tiene carga formal -2 por sus dos grupos sulfato. Sin especificar la carga, el cálculo no converge. Se recalculó indicando

`charge -2` en el archivo de control de TURBOMOLE y usando la base `def2-SVP` por el mayor tamaño de la molécula.

Paclitaxel. Con 113 átomos pesados es la segunda molécula más grande del dataset. Necesitó más de 300 ciclos de optimización y unas 72 horas de CPU por nodo.

Sirolimus. La molécula más grande, con 144 átomos. Al ser un macrolactámico flexible, tiene varios conformeros con energías similares. Se usó la geometría de PubChem 3D como punto de partida.

C.3. Archivos generados por molécula

- `coord`: coordenadas de la estructura optimizada (en Bohr)
- `energy`: historial de energías por ciclo de optimización
- `cosmo`: distribución de carga superficial para COSMO-RS
- `sigma_profile.dat`: perfil sigma en 100 puntos
- `vibspectrum`: frecuencias de vibración IR (cm^{-1})
- `molden.input`: archivo para visualización en Molden

Los perfiles sigma se extrajeron con el script `extraer_sigma_profiles.py` (Anexo~F). El rango de polaridad cubre $[-0.05, 0.05]e/\text{\AA}^2$ con paso 0.001, lo que da 100 puntos por molécula, normalizados por área superficial.

C.4. Estadísticas de convergencia

Las 58 moléculas convergieron. El número medio de ciclos fue 87, con un mínimo de 12 (Ammonia) y un máximo de 347 (Paclitaxel). El tiempo de CPU acumulado fue de aproximadamente 3 semanas de cómputo continuo.

Apéndice *D*

Resultados completos de docking

D.1. Protocolo de preparación

Las proteínas se descargaron del Protein Data Bank en formato PDB y se prepararon con MGLTools 1.5.7. El script `prepare_receptor4.py` elimina las moléculas de agua, añade hidrógenos polares y asigna cargas Gasteiger a cada átomo. Los ligandos se prepararon desde los SMILES con OpenBabel 3.1, convirtiendo al formato PDBQT que requiere AutoDock Vina.

Las cajas de búsqueda, que definen la región de la proteína donde se busca la pose de unión, se centraron en el sitio activo co-cristalizado de cada proteína. El tamaño fue de $25 \times 25 \times 25, \text{\AA}$ para todas excepto P-gp (7A65), que por su gran cavidad de unión requirió $40 \times 40 \times 40, \text{\AA}$. El docking se realizó con AutoDock Vina 1.2.5 [Eberhardt et al. \(2021\)](#) con parámetros de alta exhaustividad (32), 9 poses por cálculo y 8 CPUs.

D.2. Energías de unión

La tabla siguiente recoge las estadísticas de energía de unión ΔG (modo 1, mejor pose) para las seis proteínas. Valores más negativos indican mayor afinidad. Cisplatino no generó resultados porque AutoDock Vina no maneja el platino sin parámetros específicos.

Los datos completos por molécula están en el archivo `docking_energias_completo.csv` del repositorio. Los 342 archivos de poses están organizados por proteína en `docking/resultados/`.

Tabla D.1: Estadísticas de energía de unión por proteína (kcal/mol).

Proteína	Media	Mín.	Máx.	DE
P-gp MDR1 (7A65)	-5,07	-10,27	-0,85	1,87
CYP3A4 (1TQN)	-5,21	-9,91	-0,15	2,13
TfR1 (1CX8)	-5,08	-9,12	-1,23	1,74
FR α (4LRH)	-5,70	-9,91	-1,41	1,98
Lisozima (1LYZ)	-3,54	-7,84	-0,92	1,42
HSA (1AO6)	-4,31	-8,67	-1,05	1,61

Tabla D.2: Energía de unión media por grupo molecular (kcal/mol, media sobre las 6 proteínas).

Grupo	Media ΔG	DE
Fármacos modelo	-7,31	1,42
Ligandos targeting	-5,18	1,21
Oligómeros/Unidades	-4,43	1,18
Monómeros degradación	-3,87	0,94

Apéndice *E*

Descriptores moleculares y modelos ML

E.1. Espacio de descriptores

El dataset ML final tiene 56 moléculas. De un total de 4179 descriptores brutos calculados en cinco familias, se retuvieron 1097 tras eliminar columnas con más del 50, % de valores ausentes y columnas de varianza nula (bits de fingerprint constantes para las 56 moléculas, o descriptores 3D no calculables para alguna estructura). La tabla siguiente resume ambos recuentos por familia.

Tabla E.1: Familias de descriptores moleculares calculados y retenidos tras la limpieza.

Familia	Herramienta	Calculados	Retenidos
Descriptores 2D	RDKit	38	38
Perfiles sigma COSMO-RS	TURBOMOLE	100	100
Fingerprints Morgan/ECFP4	RDKit	2048	529
MACCS keys	RDKit	167	120
Descriptores 3D Mordred*	Mordred	1826	310
Total		4179	1097

*Incluye 4 descriptores que Mordred recalcula con el mismo nombre que un descriptor 2D (BertzCT, TPSA, LabuteASA, MW), conservados como variables independientes.

Los descriptores 2D incluyen: peso molecular, lipofilia (LogP), superficie polar (TPSA), número de donadores y aceptores de enlace de hidrógeno, enlaces rotables, índice de complejidad topológica (BertzCT), índices Chi y Kappa, y contadores de grupos funcionales.

E.2. Pipeline de preprocesado

Antes del entrenamiento se aplica escalado estadístico (RobustScaler, que es menos sensible a valores extremos que el escalado estándar) y se seleccionan las 200 variables más informativas para cada proteína (SelectKBest). El número 200 equilibra la cantidad de variables con el riesgo de sobreajuste dado el tamaño del dataset.

E.3. Resultados del Modelo 1: regresión de afinidad

Tabla E.2: R^2 y MAE (kcal/mol) en validación cruzada de 5 particiones.

Modelo	P-gp	CYP3A4	TfR1	FR α	Lisozima	HSA
R^2						
Random Forest	0,803	0,543	0,808	0,517	0,716	0,658
Gradient Boosting	0,823	0,535	0,857	0,637	0,680	0,760
SVR	0,836	0,145	0,813	0,669	0,769	0,776
MLP	-1,00	-1,06	-1,40	-1,37	-2,49	-1,52
MAE (kcal/mol)						
Random Forest	0,451	0,579	0,350	0,596	0,276	0,368
Gradient Boosting	0,397	0,584	0,321	0,547	0,273	0,314
SVR	0,371	1,003	0,379	0,525	0,287	0,352

El modelo MLP obtiene R^2 negativo en las seis proteínas (peor que predecir la media), indicio de sobreajuste severo con solo 56 muestras y se descarta como candidato viable.

E.4. Resultados del Modelo 3: clasificador

SVC y MLP rinden notablemente peor que los modelos basados en árboles, probablemente por el desbalance de clases (37 favorables / 19 desfavorables) y

Tabla E.3: Métricas del clasificador favorable/desfavorable (5-fold CV estratificado). AUC-ROC mide la capacidad de separar las dos clases; un valor de 1 es perfecto.

Modelo	AUC-ROC	Accuracy	F1
Random Forest	0,957	0,927	0,947
Gradient Boosting	0,904	0,891	0,920
SVC	0,636	0,715	0,817
MLP	0,626	0,611	0,656

la alta dimensionalidad relativa al tamaño muestral. Un test de permutación de etiquetas (20 repeticiones) da un AUC medio de 0,52 bajo la hipótesis nula, confirmando que la capacidad discriminativa del mejor modelo no es producto del azar.

E.5. Variables más importantes según SHAP

SHAP [Lundberg and Lee \(2017\)](#) mide cuánto contribuye cada variable a la predicción del modelo. Los diez descriptores con mayor peso para P-gp son todos indicadores de tamaño o complejidad molecular.

Tabla E.4: Top 10 variables por importancia SHAP (modelo RF, P-gp MDR1).

Rank	Variable	SHAP medio
1	BertzCT (complejidad topológica)	0,273
2	NumBonds (número de enlaces)	0,111
3	MW (peso molecular)	0,109
4	ExactMW (peso molecular exacto)	0,074
5	ATSC2p (autocorrelación 2D, polarizabilidad)	0,059
6	ATSC2v (autocorrelación 2D, volumen de van der Waals)	0,057
7	ATSC2m (autocorrelación 2D, masa atómica)	0,052
8	ATSC1m (autocorrelación 2D, masa atómica)	0,051
9	Chi0v (índice de conectividad valencia)	0,044
10	ATSC0v (autocorrelación 2D, volumen de van der Waals)	0,042

Con las cinco familias de descriptores realmente presentes en el entrenamiento, cuatro de los diez primeros puestos los ocupan descriptores de

autocorrelación de Mordred (ATSC*), que capturan cómo varían propiedades atómicas (masa, volumen, polarizabilidad) a lo largo del grafo molecular. Ningún perfil sigma (COSMO-RS) ni bit de fingerprint entra en el top 10 para P-gp: la forma y el tamaño de la molécula — ahora descritos tanto por índices 2D clásicos como por descriptores topológicos de Mordred — siguen explicando mejor el reconocimiento de esta bomba que su química concreta, reforzando la conclusión original con un espacio de descriptores más completo.

Apéndice *F*

Código fuente

Todos los scripts están en Python 3.12 y se organizan en dos carpetas: `cluster/` para los que se ejecutaron en HPC CENITS, y `local/` para los del Mac.

F.1. Scripts del clúster HPC

calcular_descriptores_2D.py — calcula los 38 descriptores 2D con RDKit [RDKit \(2023\)](#) a partir del CSV con los SMILES. Genera un CSV con una fila por molécula.

calcular_fingerprints.py — genera los fingerprints Morgan/ECFP4 (2048 bits) y MACCS keys (167 bits) con RDKit [RDKit \(2023\)](#). Los fingerprints codifican la presencia de patrones de subestructura.

extraer_sigma_profiles.py — lee los archivos de salida COSMO-RS de TURBOMOLE [TURBOMOLE GmbH \(2023\)](#), discretiza la distribución de carga superficial en 100 puntos y exporta un CSV con una fila por molécula.

combinar_descriptores.py — une los cinco archivos de descriptores en un único dataset ML, alineando por nombre de molécula y eliminando columnas con más del 5, % de valores perdidos.

lanzar_docking.py — automatiza los 348 dockings con AutoDock Vina [Eberhardt et al. \(2021\)](#) vía línea de comandos. Para cada par proteína-ligando genera el archivo de configuración, lanza el cálculo y extrae la energía de unión del modo 1.

extraer_docking_energias.py — parsea los archivos de salida de Vina y construye la matriz de energías 57×6 .

modelos_ML_v2.py — entrena los tres modelos (regresión, ITI y clasificador), hace validación cruzada, calcula los valores SHAP [Lundberg and Lee \(2017\)](#) y exporta todos los resultados a CSV.

F.2. Scripts locales

preparar_plip.py — combina cada proteína PDB con el ligando en pose de docking (modo 1) en un único archivo PDB listo para subir a PLIP online [Schake et al. \(2025\)](#).

graficas_pro.py — genera todas las figuras de la memoria con estilo de publicación científica usando matplotlib y seaborn.

analisis_admet.py — procesa los CSV descargados de SwissADME [Daina et al. \(2017\)](#) y genera las figuras de propiedades ADMET.

F.3. Dependencias

```
pip install -r requirements.txt
```

Los scripts del clúster se lanzan con:

```
sbatch slurm_dft.sh
python lanzar_docking.py
python modelos_ML_v2.py
```

Apéndice G

Herramienta web Streamlit

La aplicación Streamlit permite evaluar una molécula nueva sin ejecutar ningún script. Introduce el SMILES, calcula descriptores 2D y fingerprints, carga los modelos RF entrenados, predice el perfil de afinidad frente a las seis proteínas y estima el ITI. Los resultados se presentan como radar chart, tabla de afinidades, barra de progreso del ITI y recomendación del carrier más adecuado.

Instalación

Requiere Python 3.9 o superior y el entorno conda `streamlit-env`:

```
conda activate streamlit-env
cd /ruta/al/proyecto
streamlit run app.py
```

La app se abre en `http://localhost:8501`.

Pantalla de inicio

Visualización 3D interactiva

Al introducir un SMILES válido, la app muestra la estructura 2D y la estructura 3D interactiva con py3Dmol, que permite rotar la molécula y cambiar entre estilos de representación (stick, sphere, surface). También calcula las propiedades básicas (MW, LogP, TPSA, HBD/HBA), la solubilidad estimada por ESOL y el cumplimiento de la regla de Lipinski.




Figura G.2: Visualización 3D interactiva con py3Dmol y propiedades moleculares calculadas automáticamente.

Resultados del análisis

Al pulsar “Analizar’’, la app calcula los descriptores, predice los seis ΔG con los modelos RF, calcula el ITI y clasifica la molécula como favorable, moderada o desfavorable. Los resultados incluyen radar chart, tabla de afinidades y barra de progreso del ITI coloreada según la clasificación.




Figura G.3: Resultados del análisis: métricas ITI, radar chart del perfil de afinidad, tabla de ΔG predichos y recomendación de carrier.

Ranking ITI del dataset

La segunda pestaña muestra el ranking ITI de todas las moléculas del TFM, con filtro por grupo molecular y selector de número de moléculas a mostrar.




Figura G.4: Pestaña de ranking ITI. Las líneas discontinuas marcan los umbrales favorable (>66) y moderado (>33).

Comparador

La tercera pestaña permite comparar hasta 4 moléculas lado a lado.




Figura G.5: Comparador: gráfico de barras agrupadas con los ΔG predichos para las moléculas seleccionadas.




Figura G.6: Comparador: radar charts individuales de cada molécula.

Historial de sesión

La cuarta pestaña guarda todas las moléculas analizadas en la sesión actual y genera un mapa de calor de ΔG cuando hay dos o más moléculas.




Figura G.7: Pestaña de historial: mapa de calor de ΔG para todas las moléculas analizadas en la sesión actual.

Archivos del proyecto

- `app.py`: código principal de la aplicación
- `resultados_ML/models/`: modelos RF serializados con joblib
- `dataset_ML.csv`: dataset de entrenamiento
- `base_molecular_pubchem.csv`: base de datos con SMILES

Apéndice *H*

Objetivos de Desarrollo Sostenible

Este trabajo contribuye a varios Objetivos de Desarrollo Sostenible de la Agenda 2030 de Naciones Unidas.

ODS 3: Salud y bienestar. El objetivo central es mejorar la eficacia de los sistemas de liberación de fármacos para enfermedades oncológicas, inflamatorias y neurológicas. Las herramientas computacionales desarrolladas permiten identificar qué moléculas tienen mejor perfil para el transporte de fármacos antes de hacer ningún experimento, reduciendo el tiempo y el coste del desarrollo de nuevas formulaciones. Las plataformas de nanopartículas poliméricas [Danhier et al. \(2012\)](#) y dendrímeros PAMAM [Kesharwani et al. \(2018\)](#) tienen aplicaciones clínicas directas ya en desarrollo.

ODS 9: Industria, innovación e infraestructura. La plataforma combina cálculo cuántico [TURBOMOLE GmbH \(2023\)](#), simulación de unión proteína-molécula [Eberhardt et al. \(2021\)](#) y aprendizaje automático en un pipeline reproducible. La herramienta Streamlit hace accesible esta metodología a cualquier investigador sin conocimientos de programación.

ODS 12: Producción y consumo responsables. El enfoque computacional reduce el número de experimentos en laboratorio necesarios para cribar candidatos. El análisis ADMET con SwissADME [Daina et al. \(2017\)](#) descarta tempranamente moléculas con propiedades farmacológicas desfavorables, antes de llegar a fase experimental.

Bibliografía

- Daina, A., Michielin, O., and Zoete, V. (2017). SwissADME: a free web tool to evaluate pharmacokinetics, drug-likeness and medicinal chemistry friendliness of small molecules. *Scientific Reports*, 7:42717.
- Danhier, F., Ansorena, E., Silva, J. M., Coco, R., Le Breton, A., and Préat, V. (2012). PLGA-based nanoparticles: an overview of biomedical applications. *Journal of Controlled Release*, 161(2):505–522.
- Eberhardt, J., Santos-Martins, D., Tillack, A. F., and Forli, S. (2021). AutoDock Vina 1.2.0: New docking methods, expanded force field, and python bindings. *Journal of Chemical Information and Modeling*, 61(8):3891–3898.
- Grimme, S., Antony, J., Ehrlich, S., and Krieg, H. (2010). A consistent and accurate ab initio parametrization of density functional dispersion correction (DFT-D) for the 94 elements H-Pu. *Journal of Chemical Physics*, 132(15):154104.
- Kesharwani, P., Jain, K., and Jain, N. K. (2018). PAMAM dendrimers as promising nanocarriers for drug delivery. *Progress in Polymer Science*, 39(2):268–307.
- Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30:4765–4774.
- Moriwaki, H., Tian, Y.-S., Kawashita, N., and Takagi, T. (2018). Mordred: a molecular descriptor calculator. *Journal of Cheminformatics*, 10:4.
- RDKit (2023). RDKit: Open-source cheminformatics. Versión 2023.09.

- Schake, P., Bolz, S. N., Linnemann, K., and Schroeder, M. (2025). PLIP 2025: introducing protein–protein interactions to the protein–ligand interaction profiler. *Nucleic Acids Research*, 53(W1):W463–W469.
- TURBOMOLE GmbH (2023). TURBOMOLE v7.8.1. University of Karlsruhe and Forschungszentrum Karlsruhe GmbH.
- Weigend, F. and Ahlrichs, R. (2005). Balanced basis sets of split valence, triple zeta valence and quadruple zeta valence quality for H to Rn: Design and assessment of accuracy. *Physical Chemistry Chemical Physics*, 7(18):3297–3305.