



UNIVERSIDAD
DE BURGOS



Trabajo Fin de Máster

Máster Universitario en Ingeniería Biomédica

Evaluación computacional de
nanopartículas poliméricas y
dendrimeros como sistemas de liberación
de fármacos: acoplamiento molecular con
proteínas de barrera biológica y modelos
predictivos de eficiencia de transporte

Presentado por **Diego Vallina Álvarez**

Universidad de Burgos · Curso académico 2025–2026

Directores:

Santiago Aparicio Martínez

Pedro Ángel Marcos Villa



UNIVERSIDAD
DE BURGOS



D. Santiago Aparicio Martínez, profesor del Departamento de Química, Área de Química Física, Unidad de Investigación Consolidada 305 — Análisis y Simulación Molecular de Fluidos, Universidad de Burgos.

D. Pedro Ángel Marcos Villa, profesor del Departamento de Física, Área de Física Aplicada, Universidad de Burgos.

Exponen:

Que el alumno D. Diego Vallina Álvarez, con DNI 58441105Z, ha realizado el Trabajo Fin de Máster en Ingeniería Biomédica titulado:

Evaluación computacional de nanopartículas poliméricas y dendrímeros como sistemas de liberación de fármacos: acoplamiento molecular con proteínas de barrera biológica y modelos predictivos de eficiencia de transporte.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección de los que suscriben, quienes autorizan su presentación.

En Burgos, a 24 de julio de 2026

Vº. Bº. del Director:

Vº. Bº. del Director:

D. Santiago Aparicio Martínez

D. Pedro Ángel Marcos Villa

Resumen

Los sistemas de liberación de fármacos basados en nanopartículas poliméricas y dendrímeros representan una de las estrategias más prometedoras en nanomedicina. Su eficiencia de transporte depende fundamentalmente de la interacción de sus componentes moleculares con las proteínas de barrera biológica que regulan la biodistribución, el metabolismo y la captación celular de los fármacos.

Este trabajo presenta una plataforma computacional integrada para la evaluación sistemática de 60 moléculas representativas de monómeros, oligómeros, unidades de dendrímero, fármacos modelo y ligandos de targeting frente a seis proteínas de barrera clave: P-glicoproteína (P-gp/MDR1), CYP3A4, receptor de transferrina (TfR1), receptor de folato alfa (FR α), lisozima y albúmina sérica humana (HSA).

La metodología combina: (i) optimización de las geometrías y propiedades electrónicas estimadas con cálculos de mecánica cuántica; (ii) estudio de las interacciones proteína-ligando mediante docking molecular; (iii) cálculo de 1097 descriptores moleculares tras limpieza (2D, 3D, fingerprints y perfiles de polaridad superficial, de un total de 4179 calculados) y propiedades ADMET con SwissADME; y (iv) tres modelos de aprendizaje automático: regresión de afinidad por proteína (mejor modelo R^2 hasta 0.836 para P-gp), un Índice de Eficiencia de Transporte (ITI) y un clasificador favorable/desfavorable (AUC = 0.957). El análisis SHAP, que permite discernir las contribuciones principales para la afinidad con la proteína, revela que la complejidad topológica (BertzCT) es el descriptor con mayor poder predictivo. Los resultados identifican Triethylene glycol (PEG), ramas PAMAM de baja generación y oligómeros de quitosano como los candidatos más favorables para drug delivery, validado estructuralmente por PLIP y farmacocinéticamente por ADMET. El trabajo incluye una herramienta web interactiva (Streamlit) para la recomendación de carrier óptimo a partir del SMILES de una nueva molécula.

Descriptores

nanopartículas poliméricas, dendrímeros, drug delivery, acoplamiento molecular, docking, proteínas de barrera biológica, DFT, COSMO-RS, PLIP, ADMET, descriptores moleculares, aprendizaje automático, Random Forest, SHAP, índice de eficiencia de transporte, P-glicoproteína, receptor de transferrina, receptor de folato

Abstract

Polymeric nanoparticle- and dendrimer-based drug delivery systems represent one of the most promising strategies in nanomedicine. Their transport efficiency fundamentally depends on how their molecular building blocks interact with the biological barrier proteins that govern biodistribution, metabolism and cellular uptake.

This work presents an integrated computational platform for the systematic evaluation of 60 representative molecules — monomers, oligomers, dendrimer units, model drugs and targeting ligands — against six key barrier proteins: P-glycoprotein (P-gp/MDR1), CYP3A4, transferrin receptor (TfR1), folate receptor alpha (FR α), lysozyme and human serum albumin (HSA).

The methodology combines: (i) optimization of molecular geometries and electronic properties estimated with quantum mechanical calculations; (ii) study of protein–ligand interactions by molecular docking; (iii) calculation of 1097 molecular descriptors after cleaning (2D, 3D, fingerprints, surface polarity profiles, out of 4179 originally computed) and ADMET properties with SwissADME; and (iv) three machine learning models: affinity regression per protein (best model R^2 up to 0.836 for P-gp), a Transport Efficiency Index (TEI), and a favorable/unfavorable classifier (AUC = 0.957). SHAP analysis, which quantifies the individual contribution of each molecular descriptor to the predicted affinity for each protein, identifies topological complexity (BertzCT) as the most predictive descriptor. Triethylene glycol (PEG), low-generation PAMAM branches and chitosan oligomers emerge as the most favorable candidates, structurally validated by PLIP and pharmacokinetically confirmed by ADMET. An interactive Streamlit web tool for optimal carrier recommendation from the SMILES of a new molecule is also provided.

Keywords

polymeric nanoparticles, dendrimers, drug delivery, molecular docking, biological barrier proteins, DFT, COSMO-RS, PLIP, ADMET, molecular descriptors, machine learning, Random Forest, SHAP, transport efficiency index, P-glycoprotein, transferrin receptor, folate receptor

Introducción

Las enfermedades oncológicas, inflamatorias y neurológicas son un problema clínico de primera magnitud. Los sistemas de liberación de fármacos (DDS, del inglés *Drug Delivery Systems*) ofrecen una solución concreta: encapsular el principio activo, protegerlo de la degradación y liberarlo donde hace falta. Las nanopartículas poliméricas basadas en poli(ácido láctico-*co*-glicólico) (PLGA), poli(ácido láctico) (PLA) o policaprolactona llevan décadas en desarrollo clínico, y los dendrímeros de poliamidoamina (PAMAM), que son moléculas muy ramificadas con cavidades internas para cargar fármacos, representan una alternativa complementaria ([Danhier et al., 2012](#); [Kesharwani et al., 2014](#)).

Existen un cierto conjunto de proteínas que determinan qué le pasa a cualquier molécula que entra en el organismo. La P-glicoproteína (P-gp/MDR1) expulsa los fármacos que reconoce como sustratos, lo que causa resistencia a la quimioterapia ([Waghray and Zhang, 2018](#)). El CYP3A4 los metaboliza en el hígado antes de que lleguen al tumor, y es responsable del metabolismo de más del 50 % de los fármacos clínicos ([Zanger and Schwab, 2013](#)). El receptor de transferrina (TfR1) y el receptor de folato (FR α) están sobreexpresados en las células tumorales y se pueden usar como puerta de entrada para llevar nanopartículas específicamente al tumor. La lisozima es un indicador de compatibilidad tisular. Y la albúmina sérica (HSA) transporta los fármacos en sangre y determina cuánto tiempo circulan.

Evaluar experimentalmente cómo interacciona cada componente de un DDS con estas seis proteínas es inviable a gran escala. El docking computacional, que simula cómo una molécula pequeña se une a una proteína, permite cribar cientos de moléculas antes de tocar un tubo de ensayo ([Trott and Olson, 2010](#)). Los estudios existentes tienen limitaciones claras: se centran en una proteína, trabajan con conjuntos pequeños de moléculas, y ninguno integra

cálculos mecanocuánticos de estructura electrónica para obtener geometrías precisas y propiedades como punto de partida ([Maingi et al., 2012](#)).

Este trabajo construye una plataforma computacional para evaluar 60 moléculas representativas de nanopartículas poliméricas y dendrímeros frente a las seis proteínas descritas anteriormente. Los objetivos concretos son: obtener geometrías moleculares precisas y propiedades electrónicas mediante cálculos DFT y perfiles de polaridad superficial (COSMO-RS); realizar docking sistemático y analizar las interacciones estructurales con PLIP 2025; calcular descriptores moleculares y propiedades ADMET; entrenar modelos de aprendizaje automático para predecir la afinidad de unión y clasificar moléculas para drug delivery; e implementar una herramienta web que recomiende el carrier más adecuado para una molécula nueva.

Materiales y Métodos

2.1. Base de datos molecular

Se construyó una biblioteca de 60 moléculas en cuatro categorías: monómeros y productos de degradación de polímeros biodegradables (ácido láctico, glicólico, ε -caprolactona y derivados), oligómeros y unidades de dendrímero PAMAM (poliaminas, oligómeros de quitosano), fármacos modelo (doxorubicina, paclitaxel, 5-fluorouracilo, metotrexato, curcumina, cisplatino, gemcitabina, sirolimus, dexametasona, ibuprofeno) y ligandos de targeting activo (ácido fólico, biotina, galactosa, manosa, PEG-aminas y péptido RGD). Los SMILES, representación textual de la estructura química de una molécula, se obtuvieron de la base de datos PubChem ([National Center for Biotechnology Information, 2024](#)). Las coordenadas 3D iniciales se generaron con el algoritmo ETKDGv3 y se preoptimizaron mediante simulaciones de mecánica molecular de campo de fuerzas con MMFF94 ([RDKit, 2023](#)).

2.2. Optimización de geometrías (DFT)

Los cálculos de estructura electrónica se realizaron con TURBOMOLE 7.8.1 ([TURBOMOLE GmbH, 2023](#)) en el clúster HPC del Centro Extremeño de Investigación, Innovación Tecnológica y Supercomputación (CENITS) (16 núcleos, 31,GB RAM por nodo). El cálculo se llevó a cabo con el funcional híbrido B3LYP con corrección de dispersión D4 ([Grimme et al., 2010](#)) y base de funciones def2-TZVP ([Weigend and Ahlrichs, 2005](#)), al nivel de la función de densidad electrónica (DFT), con aproximación RI-J para reducir el coste computacional. Para cada molécula se realizaron tres cálculos: (i) optimización de la geometría hasta encontrar la estructura de mínima energía, (ii) cálculo de la distribución de carga superficial (COSMO-RS) para obtener

el perfil sigma, y (iii) cálculo de frecuencias de vibración IR para confirmar que la estructura corresponde a un mínimo real. El cisplatino requirió un tratamiento especial con el pseudopotencial ECP-60-mwb de Stuttgart para el platino, empleando la base def2-SVP para este átomo y def2-TZVP para el resto; el condroitín sulfato, con carga -2 , se recalculó especificando la carga formal.

2.3. Acoplamiento molecular

Las seis proteínas de barrera (Tabla 2.1) se obtuvieron del Protein Data Bank (PDB), base de datos de acceso libre que almacena estructuras tridimensionales de macromoléculas biológicas (Berman et al., 2000). Las proteínas se prepararon con MGLTools, añadiendo hidrógenos y asignando cargas atómicas Gasteiger para modelar de forma eficiente el potencial electrostático de la macromolécula mediante la estimación de sus cargas parciales. Los ligandos se convirtieron a formato PDBQT, formato de entrada requerido por AutoDock Vina que codifica las coordenadas atómicas junto con las cargas parciales y los grados de libertad rotacionales del ligando, con el objetivo de definir la flexibilidad conformacional durante el docking, con OpenBabel. El docking, que simula cómo una molécula pequeña se une a una proteína, se realizó con AutoDock Vina 1.2.5 (Eberhardt et al., 2021) con parámetros de alta exhaustividad (32), 9 poses por cálculo y 8 CPUs. Las cajas de búsqueda se centraron en los sitios de unión conocidos de cada proteína. De 348 dockings posibles se obtuvieron 342 válidos.

Tabla 2.1: Proteínas de barrera biológica empleadas en el estudio. El centro del grid indica las coordenadas cartesianas (x, y, z) en ångströms del punto central de la caja de búsqueda definida para el docking en cada proteína.

PDB	Proteína	Función	Centro grid (Å)
7A65	P-gp/MDR1	Bomba de expulsión de fármacos	160, 177, 144
1TQN	CYP3A4	Metabolismo hepático	-15, 5, -22, 0, -11, 0
1CX8	TfR1	Entrada en células por endocitosis	-28, 4, -38, 9, 147, 7
4LRH	FR α	Internalización del folato	5,2, 25,8, -1, 4
1LYZ	Lisozima	Evaluación de biocompatibilidad	17,0, 10,0, 25,0
1AO6	HSA	Transporte en sangre	7,0, 10,0, 18,0

2.4. Análisis de interacciones proteína-ligando

Las interacciones no covalentes entre los cinco candidatos con mayor Índice de Eficiencia de Transporte (ITI), métrica desarrollada en este trabajo para cuantificar el perfil global de una molécula para drug delivery, y las tres proteínas más relevantes (P-gp, Tfr1 y FR α) se analizaron con PLIP 2025 (del inglés *Protein-Ligand Interaction Profiler*) ([Schake et al., 2025](#)), una herramienta que detecta automáticamente qué tipo de contactos establece cada ligando con los residuos de la proteína: puentes de hidrógeno, contactos hidrofóbicos, puentes salinos e interacciones entre anillos aromáticos. Se procesaron 15 complejos en total.

2.5. Descriptores moleculares

Se calcularon inicialmente 4179 descriptores numéricos brutos para caracterizar cada molécula, agrupados en cinco familias: descriptores 2D calculados con RDKit ([RDKit, 2023](#)) (38 valores: peso molecular, lipofilia, superficie polar, grupos funcionales, índices de complejidad topológica); perfiles sigma COSMO-RS (100 valores que describen la distribución de densidad electrónica superficial); fingerprints Morgan/ECFP4 (2048 bits que codifican los patrones de subestructura química del entorno de cada átomo hasta un radio definido) y MACCS keys (167 bits que representan la presencia o ausencia de subestructuras químicas predefinidas) con RDKit; y descriptores 3D calculados con Mordred ([Moriwaki et al., 2018](#)) (1826 valores sobre las geometrías DFT, entre los que destacan los momentos de inercia, el volumen molecular, los índices de forma y los autovalores de la matriz de distancias). Tras eliminar columnas con más del 50, % de valores ausentes y columnas de varianza nula (bits de fingerprint constantes para todas las moléculas del dataset, o descriptores 3D no calculables para alguna estructura), el espacio final de descriptores efectivamente utilizado en los modelos se reduce a 1097 variables: 100 perfiles sigma, 529 bits de Morgan/ECFP4, 120 bits de MACCS, 38 descriptores 2D y 310 descriptores 3D de Mordred (incluyendo 4 que Mordred recalcula con el mismo nombre que un descriptor 2D — BertzCT, TPSA, LabuteASA y MW — y que se conservan como variables independientes).

2.6. Propiedades ADMET

Las propiedades de ADMET (Absorción, Distribución, Metabolismo, Excreción y Toxicidad) se calcularon con SwissADME (Daina et al., 2017) para las 60 moléculas. Se obtuvieron 49 parámetros por compuesto, destacando cinco modelos de lipofilia (LogP), solubilidad en agua, absorción intestinal, permeabilidad hematoencefálica, condición de sustrato de P-gp, inhibición de enzimas CYP450, *score* de biodisponibilidad oral, alertas de toxicidad, el cumplimiento de las reglas de Lipinski (donde incurrir en más de una violación de sus límites de peso molecular, lipofilia y enlaces de hidrógeno predice una deficiente absorción por vía oral) y accesibilidad sintética.

2.7. Modelos de aprendizaje automático

El dataset final tiene 56 moléculas (de las 60 de la biblioteca original, tras exigir que cada molécula tenga geometría DFT convergida, docking válido frente a las seis proteínas y descriptores completos) y 1097 descriptores tras la limpieza descrita arriba. Antes del entrenamiento se aplica escalado estadístico (RobustScaler) y se seleccionan las 200 variables más informativas para cada proteína (SelectKBest). Se desarrollaron tres modelos:

Modelo 1. Regresión de afinidad: Random Forest (300 árboles), Gradient Boosting (200 estimadores) y SVR (máquina de vectores soporte) para predecir la energía de unión ΔG en cada proteína. Se evalúa con validación cruzada de 5 particiones usando el Coeficiente de Determinación (R^2 , proporción de la varianza explicada por el modelo), el Error Absoluto Medio (MAE, promedio de los errores en magnitud absoluta) y la Raíz del Error Cuadrático Medio (RMSE, que mide la desviación cuadrática promedio y penaliza en mayor medida los errores grandes).

Modelo 2. Índice de Eficiencia de Transporte (ITI): puntuación de 0 a 100 que combina las seis afinidades de docking en una métrica única. Premia la afinidad por TfR1, FR α (40, % del índice), HSA (25, %) y lisozima (20, %). Penaliza la afinidad por P-gp y CYP3A4 (15, %). Incluye un factor corrector por peso molecular (**mw_factor**) que penaliza moléculas muy pequeñas o muy grandes, con umbrales de 0,1 para MW,<,60, Da, 0,4 para 60–100, Da, 0,7 para 100–150, Da, 1,0 para 150–900, Da y 0,8 para MW,>,900, Da.

Modelo 3. Clasificador binario: Random Forest, Gradient Boosting y SVC para clasificar moléculas como favorables (ITI $\geq$ 50) o desfavorables. Evaluado mediante el Área Bajo la Curva ROC (AUC-ROC, que mide la capacidad del modelo para distinguir entre clases), la precisión (proporción de pre-

dicciones positivas que son correctas) y la puntuación F1 (media armónica entre precisión y exhaustividad que evalúa el balance global del clasificador).

La interpretabilidad de los modelos se analizó con valores SHAP ([Lundberg and Lee, 2017](#)), que miden cuánto contribuye cada descriptor a la predicción final.

Herramienta web. Se implementó una aplicación Streamlit que, a partir del SMILES de una molécula, calcula descriptores, predice el perfil de afinidad frente a las seis proteínas, calcula el ITI y genera un diagrama radar del perfil de transporte con una recomendación del carrier más adecuado.

Resultados

3.1. Cálculos DFT y perfiles COSMO-RS

Las 58 estructuras moleculares convergieron sin frecuencias imaginarias, lo que confirma que todas son mínimos de energía reales. Los cálculos más exigentes fueron Paclitaxel (113 átomos pesados) y Sirolimus (144 átomos), que requirieron varios cientos de ciclos de optimización. Los perfiles sigma COSMO-RS describen la distribución de densidad electrónica en la superficie de cada molécula: valores de σ alejados de cero indican regiones polares (negativas si hay exceso de carga, positivas si hay defecto), mientras que la concentración cerca de $\sigma \approx 0$ refleja carácter apolar. Los resultados mostraron patrones claros por grupo: la doxorrubicina (fármaco modelo) presenta una distribución ancha que se extiende por toda la región polar, mientras que el ácido láctico (monómero de degradación) concentra su densidad cerca de $\sigma \approx 0$ (figura [3.1](#)).




Figura 3.1: Perfiles sigma COSMO-RS de la doxorrubicina (fármaco modelo, izquierda) y el ácido láctico L (monómero de degradación, derecha). La distribución ancha y polar de la doxorrubicina contrasta con la concentración cerca de $\sigma \approx 0$ del ácido láctico.

3.2. Acoplamiento molecular

La figura 3.2 muestra la matriz de afinidad completa, en la que cada celda representa la energía de unión ΔG (kcal/mol) de la pose más favorable (modo 1) obtenida por AutoDock Vina para un par molécula-proteína determinado: valores más negativos indican mayor afinidad de unión. Cabe señalar que, aunque se emplea la notación ΔG , los valores reportados corresponden a energías de *scoring* de docking y no a energías de Gibbs termodinámicas rigurosas; su interpretación es por tanto comparativa entre moléculas, no absoluta. Las energías medias por proteína se calcularon promediando los valores de modo 1 de las 57 moléculas frente a cada proteína, obteniendo: FR α ($\Delta G = -5,70$ kcal/mol), CYP3A4 ($-5,21$), TfR1 ($-5,08$), P-gp ($-5,07$), HSA ($-4,31$) y Lisozima ($-3,54$). Los valores individuales más negativos, que indican mayor afinidad, fueron Paclitaxel en P-gp ($-10,27$ kcal/mol) y Methotrexate tanto en CYP3A4 ($-9,91$) como en FR α ($-9,91$); el ácido fólico, pese a ser el ligando natural de FR α , obtuvo una afinidad algo menor ($-9,67$) que el metotrexato, un antifolato estructuralmente relacionado. Sirolimus en CYP3A4 obtuvo $-0,15$ kcal/mol, la interacción más débil del dataset, lo que sugiere que esta molécula elude el metabolismo hepático.

Resultados




Figura 3.2: Matriz de afinidad de docking (ΔG modo 1, kcal/mol) para las 57 moléculas frente a las 6 proteínas. Verde oscuro = alta afinidad, rojo = baja afinidad.

El mapa de correlaciones (figura 3.3), que permite identificar si las moléculas que se unen bien a una proteína tienden también a unirse bien a las demás, muestra que P-gp, TfR1, FR α y HSA están muy correlacionadas entre sí (correlación de Pearson r entre 0,90 y 0,95). La correlación más baja es entre CYP3A4 y Lisozima ($r = 0,73$), lo que tiene sentido dado que sus mecanismos de reconocimiento son distintos. La figura de dispersión ΔG frente a peso molecular (figura 3.4), que permite conocer en qué medida el tamaño molecular determina la afinidad de unión, confirma la tendencia general: las moléculas más grandes se unen con mayor afinidad a todas las proteínas debido a la existencia de más sitios de interacción. Los fármacos modelo aparecen sistemáticamente en la zona de alta afinidad.




Figura 3.3: Mapa de correlación de Pearson entre las energías de docking (izquierda) y dispersión ΔG TfR1 vs. P-gp coloreada por grupo molecular ($r = 0,95$, derecha).




Figura 3.4: Energía de docking ΔG vs. peso molecular para las seis proteínas, coloreado por grupo molecular.

3.3. Análisis de interacciones proteína-ligando (PLIP)

El análisis de los 15 complejos generó 708 contactos no covalentes en total (figura 3.5). FR α , el receptor de folato que se sobreexpresa en tumores de ovario y mama, concentra la mayor parte: 515 contactos, de los que 340 son puentes de hidrógeno. Los residuos SER174 (67 contactos) y ARG103 (64) son los más implicados; ambos son aminoácidos hidrofílicos con grupos laterales capaces de formar puentes de hidrógeno, lo que explica su papel central en el reconocimiento del ácido fólico según describen los datos cristalográficos. Los puentes salinos con ASP81 y LYS136 en los oligómeros de quitosano, aminoácidos de carga opuesta (ASP negativo, LYS positivo) que establecen interacciones electrostáticas fuertes, sugieren que Chitotriose y Chitobiose se unen en la misma cavidad de unión que el folato natural.

En P-gp, que es la principal bomba de expulsión de fármacos del organismo, 96 de los 100 contactos totales son hidrofóbicos, repartidos entre ILE730, LEU312, LEU757 y LEU760 (8 cada uno). Este patrón confirma lo que predice el análisis SHAP: P-gp reconoce sus sustratos por su forma y complejidad molecular, no por grupos químicos concretos. En TfR1, el receptor de transferrina que se usa para llevar moléculas al interior de células tumorales, aparecen 82 puentes de hidrógeno, con THR305 (10 contactos) y GLU972 (6) a la cabeza.




Figura 3.5: (Izquierda) Número de interacciones por tipo para cada proteína. (Derecha) Residuos con más contactos en FR α (4LRH).

3.4. Modelos de regresión de afinidad

Los modelos de regresión de afinidad tienen como objetivo predecir la energía de unión ΔG de cualquier molécula frente a cada una de las seis proteínas de barrera, a partir exclusivamente de sus descriptores moleculares, sin necesidad de realizar un nuevo cálculo de docking. Esto permite evaluar moléculas nuevas de forma inmediata una vez entrenado el modelo.

Cada molécula se representa mediante un vector de 1097 descriptores que concatena las cinco familias calculadas tras la limpieza descrita en Materiales y Métodos: 38 descriptores 2D, 100 valores del perfil sigma COSMO-RS, 529 bits de fingerprints Morgan/ECFP4, 120 bits de MACCS keys y 310 descriptores 3D de Mordred, todos ellos calculados sobre las geometrías optimizadas a nivel DFT. Antes del entrenamiento, SelectKBest selecciona los 200 descriptores más correlacionados con el ΔG de cada proteína concreta, de modo que el subconjunto de variables seleccionadas es distinto para P-gp, TfR1, FR α y el resto. El modelo entrena sobre esos 200 descriptores seleccionados mediante un pipeline independiente por proteína.

SVR y Gradient Boosting fueron los modelos más precisos en la mayoría de las proteínas, con Random Forest competitivo pero no siempre mejor (figura 3.6). El mejor modelo alcanzó $R^2 = 0,836$ en P-gp (SVR, MAE = 0,371 kcal/mol), 0,857 en TfR1 (Gradient Boosting) y 0,769 en Lisozima (SVR), todos por encima del umbral de 0,7 que se considera aceptable para modelos cuantitativos de actividad. En CYP3A4 (0,543, Random Forest), FR α (0,669, SVR) y HSA (0,775, SVR) el rendimiento es más modesto o limítrofe. Con 56 muestras y validación cruzada de 5 particiones, cada fold de test tiene 11 moléculas, lo que limita la capacidad predictiva y explica la desviación estándar relativamente alta de estos R^2 . El modelo MLP obtuvo sistemáticamente R^2 negativo en las seis proteínas, indicio de sobreajuste severo dado el tamaño muestral y se descarta como candidato viable para este dataset.

Los puntos con mayor error de predicción en la figura de predicción vs. real (figura 3.7) son Paclitaxel y Condroitín sulfato disacárido en P-gp, que se utiliza para modelar interacciones con glicosaminoglicanos en la superficie celular, probablemente porque su complejidad estructural está fuera del rango habitual del dataset. Ammonia es el principal outlier en TfR1 por ser la molécula más pequeña del conjunto.




Figura 3.6: R^2 de los tres modelos de regresión en validación cruzada de 5 particiones. La línea roja marca el umbral $R^2=0,7$.




Figura 3.7: Predicción vs. real para P-gp MDR1 y TfR1, coloreado por grupo molecular.

3.5. Índice de Eficiencia de Transporte (ITI)

El ITI es un índice con valor entre 0 y 100 que resume mediante un único número el perfil completo de una molécula para drug delivery: penaliza la afinidad por P-gp (expulsión) y CYP3A4 (metabolismo), y premia la

afinidad por TfR1 y FR α (entrada en células tumorales), HSA (transporte en sangre) y lisozima (compatibilidad con tejidos).

El ranking (figura 3.8) lo encabeza Triethylene glycol (PEG, ITI,=,100), seguido de Tetraethylenepentamine (87,3), Pentaethylenhexamine (85,0), Chitotriose (84,7), Chitobiose (82,7), D-Galactose (81,7) y D-Mannose (81,7). Los fármacos modelo quedan al final del dataset porque tienen alta afinidad por P-gp. El podio (Triethylene glycol, Tetraethylenepentamine, Pentaethylenhexamine) es estable frente a la reconstrucción del `mw_factor` descrita en la nota metodológica de la sección anterior; el orden exacto a partir del cuarto puesto es más sensible a esa reconstrucción y debe confirmarse frente al script original si se recupera. La posición alta de Chitotriose y Chitobiose, en cualquier caso, está respaldada de forma independiente por el análisis estructural PLIP (sección 3.3), que no depende del ITI.




Figura 3.8: Top 20 moléculas por ITI (escala 0–100), coloreadas por grupo molecular.

La distribución por grupos (figura 3.9) muestra qué ligandos de targeting y oligómeros tienen medianas de los valores ITI alrededor de 70–72, los monómeros de degradación en torno a 60, y los fármacos modelo cerca de 42 con alta variabilidad. Las figuras 3.10 y 3.11, que representan el perfil de afinidad de las ocho moléculas con mayor ITI en forma de diagrama radar,

Resultados

ilustran el patrón de Triethylene glycol: radio pequeño en P-gp y CYP3A4, moderado en Tfr1 y FR α .




Figura 3.9: Distribución del ITI por grupo molecular (boxplot + violin plot).




Figura 3.10: Perfil de afinidad de las moléculas 1–4 del ranking ITI. Mayor radio = mayor afinidad por esa proteína.




Figura 3.11: Perfil de afinidad de las moléculas 5–8 del ranking ITI.

3.6. Clasificador y valores SHAP

Las curvas ROC con bandas de confianza se muestran en la figura 3.12. Un AUC cercano a 1 significa que el modelo separa casi perfectamente moléculas

favorables de desfavorables. Random Forest obtuvo AUC-ROC = 0,957, Accuracy = 0,927 y F1 = 0,947, donde el AUC-ROC mide la capacidad discriminativa del modelo independientemente del umbral de clasificación, la Accuracy indica el porcentaje de moléculas clasificadas correctamente, y el F1 es la media armónica entre precisión y sensibilidad, útil cuando las clases no están perfectamente balanceadas. Gradient Boosting alcanzó AUC = 0,904 y Accuracy = 0,891. SVC y MLP rindieron notablemente peor (AUC 0,636 y 0,626 respectivamente), probablemente por el desbalance de clases (37 moléculas favorables frente a 19 desfavorables con el ITI corregido) combinado con el alto número de variables respecto al tamaño muestral.

Nota metodológica: el factor corrector por peso molecular del ITI (`mw_factor`, Materiales y Métodos) se recuperó a partir de los valores observados en los resultados guardados, ya que el script que lo calculaba no quedó versionado junto al resto del código; se documenta explícitamente en `calcular_ITI.py` para que el Modelo 2 sea reproducible en el futuro.

El análisis SHAP muestra qué descriptores moleculares son los más importantes para predecir la afinidad por P-gp (figura 3.13). BertzCT, que mide la complejidad topológica de una molécula cuantificando el número de caminos distintos en su grafo molecular — representación abstracta de la estructura química en la que los átomos son nodos y los enlaces son aristas —, presenta en el dataset valores que van desde 0 (Ammonia) hasta 2280 (Paclitaxel), con los fármacos modelo concentrados entre 940 y 2280 y los monómeros de degradación entre 6 y 221. Este descriptor tiene un peso SHAP de 0,27, muy por encima de NumBonds (0,11), que cuenta el número total de enlaces de la molécula; MW (0,11), que es el peso molecular; y ExactMW (0,07), que es el peso molecular exacto calculado a partir de las masas isotópicas. Los tres miden de distintas formas el tamaño y la complejidad de la molécula. En la práctica, esto significa que P-gp expulsa moléculas complejas y grandes, sin importar mucho su química concreta — el mismo patrón cualitativo que en la versión anterior del análisis, ahora con pesos SHAP recalculados sobre el espacio de descriptores completo (incluyendo sigma-profiles y Mordred 3D).




Figura 3.12: Curvas ROC del clasificador en validación cruzada de 5 particiones.




Figura 3.13: Importancia de los 15 descriptores principales según SHAP para el modelo de P-gp MDR1.

3.7. Propiedades ADMET

El análisis ADMET con SwissADME (figura 3.14) mide propiedades farmacológicas clave: qué porcentaje de moléculas de cada grupo se absorbe bien en el intestino (GI absorption), cuántas son expulsadas por P-gp, y qué índice de biodisponibilidad oral tienen.

Los monómeros de degradación tienen 0 violaciones de la regla de Lipinski (que establece que una molécula con peso molecular ≤ 500 Da, $\text{LogP} \leq 5$, no más de 5 donadores y 10 aceptores de puentes de hidrógeno tiene probabilidad de ser un fármaco oral) y el 67 % con absorción intestinal alta. Los oligómeros presentan una media de 1,5 violaciones y 65 % de absorción. Los ligandos de targeting obtienen el mejor índice de biodisponibilidad oral ($\text{BA} \approx 0,85$) y 87 % de absorción. Los fármacos modelo tienen en media 1,75 violaciones, 20 % de absorción intestinal alta y el 80 % son sustratos de P-gp. Los monómeros de degradación no son sustratos de P-gp en ningún caso.




Figura 3.14: Propiedades ADMET por grupo molecular: violaciones Lipinski (izquierda), porcentaje de sustratos P-gp (centro) y biodisponibilidad oral vs. lipofilia (derecha).

3.8. Herramienta web de recomendación de carrier

Como resultado final de la plataforma computacional, se implementó una herramienta web interactiva desarrollada con Streamlit que permite evaluar cualquier molécula nueva sin necesidad de ejecutar ningún script ni cálculo externo. El flujo de trabajo es el siguiente: el usuario introduce el SMILES de la molécula, la herramienta calcula automáticamente los descriptores 2D con RDKit, aplica los modelos Random Forest entrenados para predecir el ΔG frente a las seis proteínas de barrera, calcula el ITI y genera un

Resultados

diagrama radar con el perfil de afinidad completo. A partir de ese perfil, la herramienta emite una recomendación del carrier más adecuado entre las opciones evaluadas en este trabajo (nanopartículas PLGA/PLA, dendrímeros PAMAM o recubrimientos de quitosano), indicando además si la molécula se clasifica como favorable o desfavorable para drug delivery según el clasificador binario.

La herramienta está diseñada para ser utilizada en fases tempranas del diseño de nanocarriers, como filtro rápido previo a cálculos más costosos como el docking o la simulación DFT.

Discusión

4.1. Geometrías DFT y perfiles sigma

Usar estructuras moleculares optimizadas a nivel mecanocuántico (DFT) en lugar de geometrías estimadas por métodos de campo de fuerza, que no consideran explícitamente los electrones de las moléculas, tiene mayor grado de verosimilitud. Para moléculas grandes con tensión conformacional, como el sirolimus o el paclitaxel, las diferencias geométricas son suficientes para cambiar los perfiles sigma. Estos perfiles describen cómo se distribuye la polaridad en la superficie de la molécula, algo que los descriptores globales como LogP o TPSA no capturan con la misma precisión. Es importante resaltar que los estudios previos que calculan descriptores directamente desde SMILES asumen una geometría que puede estar lejos de aquella que se corresponde con el mínimo real de energía.

4.2. Interpretación de los modelos

BertzCT domina el análisis SHAP con un peso de 0,27, frente a 0,11 de NumBonds y 0,11 de MW. Los tres miden, de distintas formas, el tamaño y la complejidad de la molécula. P-gp tiene un sitio de unión de gran tamaño, de unos 5000,Å³, y reconoce sus sustratos principalmente por su hidrofobicidad y complejidad topológica, no por grupos químicos específicos ([Seelig, 1998](#)). Los resultados coinciden con lo que describe la literatura.

La correlación alta entre P-gp y Tfr1 ($r = 0,95$) tiene una implicación práctica importante: diseñar una molécula con alta afinidad por Tfr1 (para dirigirla a células tumorales) probablemente también aumentará su afinidad por P-gp (que la expulsará). En este contexto el valor ITI se hace necesario,

dado que una métrica que mida sólo la afinidad por TfR1 no detecta ese conflicto.

El rendimiento moderado en CYP3A4 (mejor $R^2 = 0,543$) y $FR\alpha$ (mejor $R^2 = 0,669$) es esperable para una muestra de 56 moléculas con validación cruzada de 5 particiones. Con 11 muestras de test por fold, cabe esperar un margen limitado para cualquier modelo. SVR y Gradient Boosting funcionan mejor que Random Forest en la mayoría de las proteínas bajo estas condiciones, aunque con desviaciones estándar altas entre folds.

4.3. Validación estructural con PLIP

Los 708 contactos identificados por PLIP dan contexto molecular a los resultados de docking. En $FR\alpha$, los residuos SER174 (67 contactos) y ARG103 (64) son exactamente los que la cristalografía identifica como esenciales para reconocer el ácido fólico. Que los oligómeros de quitosano se acoplen en la misma cavidad sugiere que podrían funcionar como ligandos de targeting: $FR\alpha$ está sobreexpresado en tumores ováricos y de mama, así que una molécula que compita con el folato por ese sitio podría usarse para dirigir un nanocarrier específicamente a esos tumores.

En P-gp, los 96 contactos hidrofóbicos con ILE730, LEU312, LEU757 y LEU760 (8 cada uno) confirman lo que predice SHAP. Triethylene glycol y Tetraethylenepentamine forman muy pocos de esos contactos, lo que explica cuantitativamente por qué tienen ITI alto.

4.4. Relevancia del ITI y propiedades ADMET

Triethylene glycol (PEG, ITI=,100) tiene el perfil más limpio: 0 violaciones de Lipinski, biodisponibilidad oral alta y 0 % de sustrato P-gp. Las ramas PAMAM de baja generación (Tetraethylenepentamine con ITI=,87,3 y Pentaethylenehexamine con 85,0) combinan buena afinidad por TfR1 con poca interacción con P-gp.

La información más relevante proviene del análisis ADMET: el 80 % de los fármacos modelo son sustratos de P-gp, frente al 0 % de los monómeros de degradación. Eso cuantifica el problema que resuelven los nanocarriers: si el fármaco está encapsulado en una partícula cuyo recubrimiento no es sustrato de P-gp, la bomba no puede expulsarlo directamente. Es una ventaja que los

ensayos clínicos con formulaciones de nanopartículas PLGA y PAMAM han confirmado experimentalmente (Soma et al., 2000; Danhier et al., 2012).

Chitotriose (ITI,=,84,7) y Chitobiose (82,7) tienen un perfil equilibrado: buena afinidad por FR α confirmada por PLIP, poca interacción con P-gp y pocas violaciones de Lipinski. El quitosano ya se usa ampliamente como recubrimiento de nanopartículas en formulaciones clínicas, así que estos resultados refuerzan las evidencias experimentales.

4.5. Limitaciones

El tamaño del dataset es la limitación principal. Con 56 moléculas y cálculos DFT completos, con un alto grado de exactitud, el coste computacional es el factor que lo acota. La ausencia de validación experimental es inherente al carácter computacional del trabajo. Los valores de ΔG obtenidos son coherentes con los publicados en estudios de docking frente a P-gp y FR α con moléculas de características similares, donde se reportan rangos típicos de -4 a -10 kcal/mol (Dolghih et al., 2011; Maingi et al., 2012). Los residuos identificados por PLIP coinciden con datos cristalográficos. Los pesos del ITI se definieron con criterio experto, es decir, asignados manualmente en función del conocimiento farmacológico sobre el papel de cada proteína en el transporte de fármacos, sin ajuste empírico sobre datos experimentales reales. Con datos de biodistribución real (mediciones de concentración del fármaco en tejidos obtenidas en ensayos in vivo) se podrían calibrar esos pesos de forma objetiva y cuantitativa, en lugar de depender del juicio del investigador.

Durante la preparación final de este trabajo se detectó y corrigió un error en el script de combinación de descriptores (`combinar_descriptores.py`): una discrepancia de formato en los nombres de molécula entre `docking_energias.csv` (que usa guiones bajos) y el resto de archivos (que usan espacios) hacía que el *merge* por nombre solo emparejara una fracción de las moléculas, lo que a su vez provocaba que las familias de perfiles sigma COSMO-RS y de descriptores 3D de Mordred se descartaran por completo del conjunto de entrenamiento durante la limpieza de columnas con datos ausentes. Todas las cifras de este capítulo corresponden a la versión corregida del pipeline (nombres normalizados, sin descriptores duplicados, con las cinco familias de descriptores realmente presentes). Los resultados de regresión se mantienen en el mismo orden de magnitud que con el pipeline original e incluso mejoran para varias proteínas, lo que sugiere que las conclusiones del trabajo no dependían de ese error, pero sí

subraya la importancia de una comprobación de cobertura del *merge* como parte del pipeline (incluida ahora en `combinar_descriptores.py`).

El AUC-ROC obtenido por el clasificador (0,957 Random Forest, 0,904 Gradient Boosting) debe interpretarse con cautela dado el tamaño muestral: con 56 moléculas y validación cruzada de 5 particiones, cada fold de test contiene únicamente 11 muestras, lo que produce curvas ROC de forma escalonada y valores de AUC más extremos que los que cabría esperar con un conjunto de test mayor. Además, la selección de 200 descriptores de un total de 1097 candidatos, aplicada dentro de cada fold de entrenamiento (evitando fuga de información), opera en un régimen de alta dimensionalidad relativa a la muestra ($p \gg n$) que favorece un cierto optimismo en las métricas de validación cruzada. Para descartar que la separación observada se deba al azar, se realizó un test de permutación: se barajaron aleatoriamente las etiquetas favorable/desfavorable 20 veces y se repitió el mismo procedimiento de validación cruzada sobre cada barajado. El AUC medio obtenido con etiquetas aleatorias fue 0,52 (máximo 0,73 en las 20 repeticiones), muy por debajo del AUC real, lo que respalda que la capacidad discriminativa del modelo refleja una señal genuina en los datos y no un ajuste espurio al ruido. Aun así, la clasificación es una tarea más permisiva que la regresión de ΔG , ya que solo requiere acertar el lado de un umbral definido sobre una combinación de las seis afinidades de docking, afinidades que a su vez ya se predicen razonablemente bien desde los descriptores moleculares.

Por último, el factor corrector por peso molecular del ITI (`mw_factor`) se reconstruyó a partir de los valores observados en los resultados guardados, ya que el script que lo generaba originalmente no quedó versionado en el repositorio. La reconstrucción reproduce con fidelidad el podio del ranking ITI (Triethylene glycol, Tetraethylenepentamine, Pentaethylenehexamine) pero introduce incertidumbre en el orden exacto de las moléculas siguientes y, por extensión, en qué moléculas concretas caen a cada lado del umbral favorable/desfavorable del clasificador. Se recomienda confirmar estas cifras si el script original se recupera.

Conclusiones

Se ha construido una plataforma computacional completa para evaluar componentes moleculares de nanopartículas poliméricas y dendrímeros frente a seis proteínas que determinan cómo se distribuye y metaboliza un fármaco en el organismo. Las conclusiones principales son:

1. Las 58 estructuras moleculares se optimizaron a nivel cuántico mediante cálculos DFT sin que ninguna presentara frecuencias imaginarias. Los perfiles de polaridad superficial (COSMO-RS) y las frecuencias de vibración IR se calcularon para todas las moléculas, incluidos los casos especiales como el cisplatino y el condroitín sulfato.
2. El protocolo de docking generó 342 resultados válidos frente a seis proteínas. La matriz de energías de unión resultante separa claramente fármacos, oligómeros y ligandos de targeting, con valores medios entre $-3,54$ y $-5,70$ kcal/mol según la proteína.
3. El análisis de interacciones con PLIP identificó 708 contactos no covalentes en 15 complejos. Los residuos clave de FR α (SER174, ARG103) y P-gp (ILE730, LEU312, LEU757) coinciden con los datos cristalográficos publicados, lo que valida las poses de docking obtenidas.
4. Los modelos de regresión superaron $R^2 = 0,7$ en tres proteínas: P-gp ($R^2 = 0,836$, SVR, MAE = $0,371$ kcal/mol), Tfr1 ($0,857$, Gradient Boosting) y Lisozima ($0,769$, SVR). El conjunto final de 1097 descriptores (tras eliminar columnas constantes o con datos ausentes de un total de 4179 calculados) es suficientemente informativo para predecir la afinidad de unión con este dataset.

5. El ITI identifica Triethylene glycol (100), Tetraethylenepentamine (87, 3) y Pentaethylenehexamine (85, 0) como los candidatos más favorables, seguidos por Chitotriose (84, 7) y Chitobiose (82, 7), cuya posición alta está además respaldada de forma independiente por el análisis PLIP. Todos son componentes habituales en formulaciones de nanopartículas clínicas.
6. El análisis ADMET confirma que el 80 % de los fármacos modelo son sustratos de P-gp frente al 0 % de los monómeros de degradación. Ese contraste cuantifica el problema que resuelven los nanocarriers con ITI alto: al encapsular el fármaco, se reduce la exposición directa a la bomba de expulsión.
7. El descriptor BertzCT, que mide la complejidad topológica de una molécula, tiene el mayor peso en el análisis SHAP (valor medio 0, 27), seguido de NumBonds (0, 11) y MW (0, 11). P-gp selecciona sus sustratos principalmente por tamaño y complejidad estructural, no por grupos químicos concretos.
8. El clasificador binario alcanza $AUC-ROC = 0,957$ y $Accuracy = 0,927$ (Random Forest); un test de permutación de etiquetas confirma que esta capacidad discriminativa no es producto del azar (AUC medio con etiquetas aleatorias = 0, 52). El espacio de descriptores moleculares separa razonablemente bien las moléculas favorables de las desfavorables para drug delivery.
9. La herramienta Streamlit permite evaluar cualquier molécula nueva introduciendo su SMILES: calcula descriptores, predice el perfil de afinidad, estima el ITI y recomienda el carrier más adecuado sin necesidad de ejecutar ningún script.

Líneas de trabajo futuro

El trabajo más evidente es ampliar el dataset. Con 200 a 500 moléculas, incluyendo generaciones superiores de PAMAM (G3-G5) y más variedad de ligandos de targeting, los modelos de regresión mejorarían notablemente. Con ese volumen de datos también sería posible probar arquitecturas de aprendizaje profundo como redes neuronales de grafos (GNN), que trabajen directamente con la estructura molecular en lugar de con descriptores numéricos calculados a mano.

La validación experimental es el paso que más valor daría a las predicciones. Ensayos de inhibición de P-gp, estudios de captación celular mediada por TfR1 o experimentos de biodistribución en animales permitirían comparar las energías de unión predichas con datos reales. Con esos datos también se podrían ajustar los pesos del ITI de forma empírica, en lugar de definirlos con criterio experto, es decir, asignados manualmente en función del conocimiento farmacológico sobre el papel de cada proteína, sin ajuste sobre datos experimentales reales.

En cuanto al docking, aplicar métodos más precisos como FEP (*Free Energy Perturbation*, perturbación de energía libre) o MM-GBSA (*Molecular Mechanics Generalized Born Surface Area*, mecánica molecular con modelo de solvatación implícita) a los candidatos top del ITI daría una caracterización energética más fiable. A diferencia de AutoDock Vina, que estima la afinidad mediante una función de scoring rápida, estos métodos calculan la energía libre de unión considerando explícitamente la flexibilidad del receptor y los efectos del disolvente, a costa de un coste computacional mucho mayor. Para un conjunto reducido de candidatos son abordables.

La herramienta Streamlit tiene margen de mejora. Añadir un módulo de dibujo de estructuras moleculares directamente en el navegador, exportación de

Líneas de trabajo futuro

informes en PDF y conexión con bases de datos como PubChem o ChEMBL haría que fuera más útil para investigadores que no estén familiarizados con códigos SMILES.

Bibliografía

- Berman, H. M., Westbrook, J., Feng, Z., Gilliland, G., Bhat, T. N., Weissig, H., Shindyalov, I. N., and Bourne, P. E. (2000). The protein data bank. *Nucleic Acids Research*, 28(1):235–242.
- Daina, A., Michielin, O., and Zoete, V. (2017). SwissADME: a free web tool to evaluate pharmacokinetics, drug-likeness and medicinal chemistry friendliness of small molecules. *Scientific Reports*, 7:42717.
- Danhier, F., Ansorena, E., Silva, J. M., Coco, R., Le Breton, A., and Préat, V. (2012). PLGA-based nanoparticles: An overview of biomedical applications. *Journal of Controlled Release*, 161(2):505–522.
- Dolgih, E., Bryant, C., Renslo, A. R., and Jacobson, M. P. (2011). Predicting binding to P-glycoprotein by flexible receptor docking. *PLOS Computational Biology*, 7(6):e1002083.
- Eberhardt, J., Santos-Martins, D., Tillack, A. F., and Forli, S. (2021). AutoDock Vina 1.2.0: New docking methods, expanded force field, and python bindings. *Journal of Chemical Information and Modeling*, 61(8):3891–3898.
- Grimme, S., Antony, J., Ehrlich, S., and Krieg, H. (2010). A consistent and accurate ab initio parametrization of density functional dispersion correction (DFT-D) for the 94 elements H–Pu. *The Journal of Chemical Physics*, 132(15):154104.
- Kesharwani, P., Jain, K., and Jain, N. K. (2014). PAMAM dendrimers as efficient drug and gene delivery nanosystems for cancer therapy. *Colloids and Surfaces B: Biointerfaces*, 118:146–159.

- Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30:4765–4774.
- Maingi, V., Kumar, M. V. S., Bhargava, B., and Maiti, P. K. (2012). Dendrimer building blocks in the presence of a physiological pH buffer: A computer simulation study. *The Journal of Physical Chemistry B*, 116(16):4968–4978.
- Moriwaki, H., Tian, Y.-S., Kawashita, N., and Takagi, T. (2018). Mordred: a molecular descriptor calculator. *Journal of Cheminformatics*, 10(1):4.
- National Center for Biotechnology Information (2024). PubChem database. <https://pubchem.ncbi.nlm.nih.gov/>. Accessed: June 2026.
- RDKit (2023). RDKit: Open-source cheminformatics. Available from <https://www.rdkit.org>.
- Schake, P., Bolz, S. N., Linnemann, K., and Schroeder, M. (2025). PLIP 2025: introducing protein–protein interactions to the protein–ligand interaction profiler. *Nucleic Acids Research*, 53(W1):W463–W469.
- Seelig, A. (1998). A general pattern for substrate recognition by p-glycoprotein. *European Journal of Biochemistry*, 251(1-2):252–261.
- Soma, C. E., Dubernet, C., Bentolila, D., Benita, S., and Couvreur, P. (2000). Reversion of multidrug resistance by co-encapsulation of doxorubicin and cyclosporin a in polyalkylecyanoacrylate nanoparticles. *Biomaterials*, 21(1):1–7.
- Trott, O. and Olson, A. J. (2010). AutoDock Vina: Improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *Journal of Computational Chemistry*, 31(2):455–461.
- TURBOMOLE GmbH (2023). TURBOMOLE v7.8.1. A development of University of Karlsruhe and Forschungszentrum Karlsruhe GmbH. Available from <http://www.turbomole.com>.
- Waghray, D. and Zhang, Q. (2018). Inhibit or evade multidrug resistance P-glycoprotein in cancer treatment. *Journal of Medicinal Chemistry*, 61(12):5108–5121.
- Weigend, F. and Ahlrichs, R. (2005). Balanced basis sets of split valence, triple zeta valence and quadruple zeta valence quality for H to Rn: Design and assessment of accuracy. *Physical Chemistry Chemical Physics*, 7(18):3297–3305.

- Zanger, U. M. and Schwab, M. (2013). Cytochrome P450 enzymes in drug metabolism: regulation of gene expression, enzyme activities, and impact of genetic variation. *Pharmacology & Therapeutics*, 138(1):103–141.