UNIVERSIDAD DE BURGOS
Máster Universitario en Ingeniería Biomédica

PROPUESTA DE TRABAJO FIN DE MÁSTER

Evaluación computacional de nanopartículas poliméricas y dendrímeros como sistemas de liberación de fármacos: acoplamiento molecular con proteínas de barrera biológica y modelos predictivos de eficiencia de transporte

Alumno: Diego Vallina

Grupo de Química-Física Computacional
Departamento de Química / Departamento de Física
Directores: Prof. Santiago Aparicio / Prof. Pedro A. Marcos

Curso Académico 2025-2026

1. DATOS IDENTIFICATIVOS

Título	Evaluación computacional de nanopartículas poliméricas y dendrímeros como sistemas de liberación de fármacos: acoplamiento molecular con proteínas de barrera biológica y modelos predictivos de eficiencia de transporte
Máster	Máster Universitario en Ingeniería Biomédica
Director	Prof. Santiago Aparicio
Departamento	Profs. Santiago Aparicio / Pedro A. Marcos
Grupo	Grupo de Química-Física Computacional
Tipo	Investigación computacional - Nanomedicina
Duración estimada	9 créditos

2. RESUMEN

Este Trabajo Fin de Máster aborda la evaluación computacional de nanopartículas poliméricas (PLGA, PLA, quitosano, polιε-caprolactona) y dendrímeros (PAMAM de generaciones G1-G4) como sistemas de liberación controlada de fármacos. Esta propuesta se centra en cómo los componentes moleculares de los nanocarriers poliméricos y los fármacos que transportan interactúan con las proteínas de barrera biológica que determinan la eficiencia del transporte y liberación del fármaco.

El enfoque combina: (i) acoplamiento molecular con AutoDock Vina de monómeros, oligoméros, unidades de dendrímero, fármacos modelo y ligandos de targeting contra 6 proteínas clave del transporte biológico (P-glicoproteína, CYP3A4, receptor de transferrina, receptor de folato, lisozima y HSA como transportador); (ii) cálculo de descriptores moleculares específicos de drug delivery; y (iii) modelos de aprendizaje automático para predecir un índice de eficiencia de transporte. La herramienta final recomendará el carrier óptimo para un fármaco dado.

3. ANTECEDENTES Y JUSTIFICACIÓN

3.1. NPs poliméricas y dendrímeros en drug delivery

Las nanopartículas poliméricas biodegradables, especialmente las basadas en PLGA, constituyen la plataforma de drug delivery más avanzada clínicamente, con múltiples formulaciones aprobadas por la FDA (Lupron Depot®, Zoladex®). Los dendrímeros PAMAM representan una clase complementaria: macromoléculas altamente ramificadas con cavidades internas para encapsulación y grupos amino terminales para funcionalización. La combinación de ambas plataformas (híbridos dendrímero-PLGA) es una dirección emergente de gran interés.

3.2. Barreras biológicas: las proteínas que determinan la eficiencia del DDS

La eficiencia de un DDS depende de su capacidad para: (a) evitar el metabolismo prematuro (CYP3A4), (b) superar bombas de eflujo (P-gp/MDR1), (c) ser internalizado por células diana (TfR1, FRα), (d) ser biocompatible con el entorno tisular (lisozima), y (e) aprovechar el transporte plasmático (HSA). Estas 6 proteínas constituyen las dianas de este estudio.

3.3. Justificación del enfoque molecular para docking

AutoDock Vina opera con ligandos pequeños-medianos. El enfoque de este TFM utiliza como ligandos los componentes moleculares de los DDS: monómeros de degradación (ácido láctico, glicólico), oligoméros de superficie (dímeros/trímeros PLGA, ramas PAMAM G0-G2), fármacos modelo (doxorrubicina, paclitaxel, 5-FU) y ligandos de targeting (ácido fólico, PEG, péptidos RGD). Este enfoque molecular está bien precedentado en la literatura.

4. OBJETIVOS

4.1. Objetivo general

Desarrollar una plataforma computacional para evaluar la interacción de componentes moleculares de DDS poliméricos y dendriméricos con proteínas de barrera biológica, y predecir mediante ML la eficiencia de transporte de nuevas formulaciones.

4.2. Objetivos específicos

1. Construir una base de datos de al menos 50 moléculas: monómeros/oligoméros de polímeros, unidades PAMAM, fármacos modelo y ligandos de targeting.
2. Seleccionar, preparar y validar 6 proteínas de barrera: P-gp (7A65), CYP3A4 (1TQN), TfR1 (1CX8), FRα (4LRH), lisozima (1LYZ), HSA (1AO6).
3. Realizar docking sistemático con AutoDock Vina: 300+ cálculos (50 moléculas × 6 proteínas).
4. Analizar interacciones moleculares con PyMOL/PLIP centradas en preguntas de drug delivery.
5. Calcular descriptores moleculares específicos de drug delivery: ADMET, biodegradabilidad, encapsulación, permeabilidad.
6. Desarrollar modelos ML: predicción de afinidad, índice de eficiencia de transporte y clasificador de formulaciones.
7. Implementar herramienta Python/Streamlit con módulo de recomendación de carrier óptimo.

5. METODOLOGÍA

5.1. Base de datos molecular (Etapa 1)

Se construirá una biblioteca de 50+ moléculas en 4 categorías:

Categoría	Moléculas representativas	Justificación

Monómeros / degradación	Ácido láctico (L/D), glicólico, ε-caprolactona, glucosamina, N-acetilglucosamina, etilendiamina, acrilato de metilo	Productos de degradación in vivo que interactúan con proteínas metabólicas
Oligoméros / unidades dendrímero	Dímeros/trímeros PLGA, PLA, PCL; ramas PAMAM G0, G1; fragmentos quitosano (2-4 unidades)	Superficie del nanocarrier que media interacciones con proteínas
Fármacos modelo	Doxorrubicina, paclitaxel, 5-FU, metotrexato, curcumina, cisplatino, gemcitabina, sirolimus, dexametasona, ibuprofeno	Fármacos frecuentemente encapsulados en DDS poliméricos
Ligandos targeting	Ácido fólico, PEG-amina, péptido RGD, péptido TAT, biotina, galactosa, manosa, fragmento ác. hialurónico	Moléculas de superficie para targeting activo

5.2. Proteínas de barrera biológica (Etapa 2)

Proteína	PDB	Función en drug delivery	Relevancia clínica
P-glicoproteína (P-gp/MDR1)	7A65	Bomba de eflujo ATP-dependiente	Resistencia multidroga; barrera BHE
CYP3A4	1TQN	Metabolismo hepático de fármacos	Biodisponibilidad oral
Receptor de transferrina (TfR1)	1CX8	Endocitosis mediada por receptor	Targeting tumoral y paso de BHE
Receptor de folato α (FRα)	4LRH	Internalización conjugados folato	Sobreexpresado en tumores ováricos, mama
Lisozima humana	1LYZ	Interacción inespecífica tisular	Evaluación biocompatibilidad
HSA (como transportador)	1AO6	Transporte plasmático	Extensión vida media (nab-technology)

Diferenciación respecto a Propuesta 1: HSA se estudia como proteína de transporte (no como formadora de corona tóxica), y las otras 5 proteínas son completamente distintas.

5.3. Acoplamiento molecular (Etapa 3)

- Grid box 25×25×25 Å, exhaustiveness = 32, 300+ dockings.
- Análisis dual en P-gp: docking fármaco solo vs. fármaco + fragmentos carrier.
- Múltiples sitios en HSA (Sudlow I, II, IIIA) y P-gp (sitio sustrato, sitio modulador).
- Automatización completa mediante Python (Meeko + Vina CLI).

5.4. Análisis de interacciones (Etapa 4)

- ¿Los productos de degradación inhiben CYP3A4? Interacción sinergética con el fármaco.
- ¿Fragmentos PAMAM inhiben P-gp? Implicaciones para superar resistencia multidroga.
- ¿Qué ligandos de targeting maximizan afinidad por TfR1 y FRα?
- Residuos clave, farmacóforos y patrones con PyMOL/PLIP.

5.5. Descriptores moleculares (Etapa 5)

- Clásicos: MW, LogP, TPSA, HBD, HBA, fingerprints Morgan/ECFP4, MACCS (RDKit/Mordred).

- Biodegradabilidad: enlaces éster/amida hidrolizables, LogP del monómero.
- Encapsulación: ΔLogP fármaco-carrier, descriptores de forma (PMI, asphericity).
- ADMET del fármaco: Caco-2, ESOL, CYP450, inhibición P-gp (pkCSM/SwissADME).
- Docking: ΔG por proteína, ratio afinidad libre/con carrier, eficiencia de ligando.

5.6. Modelos de ML (Etapa 6)

1. Modelo 1 - Regresión de afinidad: RF, XGBoost, SVR, MLP por proteína. 5-fold CV + test 20%.
2. Modelo 2 - Índice de eficiencia de transporte (ITI): combina afinidades en métrica única. Alta afinidad por TfR1/FRα + baja afinidad por P-gp/CYP3A4 = favorable.
3. Modelo 3 - Clasificador favorable/desfavorable para drug delivery.
4. Interpretabilidad: SHAP values. Validación contra datos experimentales publicados.

5.7. Herramienta computacional (Etapa 7)

Streamlit app: seleccionar polímero + fármaco → descriptores → docking → ITI predicho → radar chart de perfil → recomendación de carrier óptimo.

6. PLAN DE TRABAJO

Fase	Periodo	Descripción
Fase 1	Semanas 1-2	Revisión bibliográfica DDS poliméricos/dendrímeros y formación
Fase 2	Semanas 3-4	Base de datos molecular y preparación proteínas de barrera
Fase 3	Semanas 4-6	Docking sistemático y análisis de interacciones
Fase 4	Semanas 7-8	Descriptores moleculares y propiedades ADMET
Fase 5	Semanas 9-11	Modelos ML: regresión, índice transporte y clasificación
Fase 6	Semanas 12-13	Implementación herramienta web
Fase 7	Semanas 14-16	Validación, análisis y redacción memoria

7. SOFTWARE Y RECURSOS

- AutoDock Vina v1.2.x: acoplamiento molecular.
- PyMOL / ChimeraX / PLIP / LigPlot+: visualización e interacciones.
- RDKit / Mordred: descriptores moleculares y generación oligoméros.
- Avogadro / Open Babel / Meeko: preparación estructuras.
- Python 3.x: scikit-learn, XGBoost, PyTorch, Pandas, Matplotlib, Plotly.
- Streamlit: interfaz web. SwissADME / pkCSM: ADMET in silico.

8. RESULTADOS ESPERADOS

1. Base de datos de 50+ moléculas DDS con descriptores y propiedades ADMET.

2. Protocolos docking validados (RMSD < 2.0 Å) para 6 proteínas de barrera.
3. Matriz afinidad 300+ dockings con análisis hits prioritarios.
4. Modelos ML validados: $R^2 > 0.7$, índice transporte, clasificador formulaciones.
5. Herramienta con módulo recomendación carrier óptimo.
6. Memoria TFM y potencial manuscrito.

9. COMPETENCIAS

- Diseño racional de sistemas de liberación de fármacos y barreras biológicas.
- Acoplamiento molecular y análisis de interacciones proteína-ligando.
- Programación Python para cribado computacional.
- ML aplicado a nanomedicina y drug delivery.
- Evaluación ADMET computacional.
- Desarrollo de aplicaciones web científicas.

10. BIBLIOGRAFÍA

[1] Trott, O. & Olson, A.J. (2010). AutoDock Vina: Improving the speed and accuracy of docking. J. Comput. Chem., 31(2), 455-461.

[2] Eberhardt, J. et al. (2021). AutoDock Vina 1.2.0: New docking methods. J. Chem. Inf. Model., 61(8), 3891-3898.

[3] Kesharwani, P. et al. (2018). PAMAM dendrimers as efficient drug and gene delivery nanosystems for cancer therapy. Colloids Surf. B, 165, 146-159.

[4] Maingi, V. et al. (2012). Molecular modeling to study dendrimers for biomedical applications. Molecules, 17(4), 4474-4508.

[5] Danhier, F. et al. (2012). PLGA-based nanoparticles: An overview of biomedical applications. J. Control. Release, 161(2), 505-522.

[6] Yang, H. et al. (2012). Hybrid dendrimer hydrogel/PLGA nanoparticle platform. ACS Nano, 6(9), 7595-7606.

[7] Waghray, D. & Zhang, Q. (2018). Inhibit or evade multidrug resistance P-glycoprotein. J. Med. Chem., 61(12), 5108-5121.

[8] Zanger, U.M. & Schwab, M. (2013). Cytochrome P450 enzymes in drug metabolism. Pharmacol. Ther., 138(1), 103-141.

[9] Moriwaki, H. et al. (2018). Mordred: a molecular descriptor calculator. J. Cheminform., 10, 4.

[10] Noriega-Luna, B. et al. (2014). Applications of dendrimers in drug delivery agents, diagnosis, therapy, and detection. J. Nanomater., 2014, 507273.